Отчет по проекту

Постановка задачи

Гипотеза: различные трансформации таргета по разному влияют на качество прогнозирования глобальной модели в зависимости от типа временного ряда

Цель: определить какая из 4 трансформаций будет самой полезной для модели catboost и зависит ли ответ от характеристик ряда

Рассматриваемые трансформации:

1. **Identity**
2. **log1p** - логарифмическое преобразование
3. **Box-Cox** — преобразование Бокса-Кокса с единым labmda для всех рядов
4. **Differencing** — первые разности

Описание данных

Был взят датасет M4 monthly из forecastingdata.org. Случайным образом было отобрано 150 рядов, период сезонности - 12, горизонт прогнозирования - 18 шагов

Последние 18 наблюдений каждого ряда - тест, остальное - обучение

Методология эксперимента

Кластеризация рядов

Для ответа на вопрос “какая трансформация полезнее для каких типов рядов” необходимо разделить ряды на группы по их характеристикам

Из каждого ряда извлечены статистические признаки:

признак	
mean, std, cv	уровень, вариабельность, коэф вариации
trend_strength	сила тренда
seasonality_strength	сила сезонности
acf1, acf_seasonal	автокорреляция на лаге 1 и на сезонном лаге (12)
diff_acf1	автокореляция первых разностей
skewness, kurtosis	асиметрия и эксцесс
length	длина ряда

После стандартизации признаков применен **KMeans**. Оптимальное число кластеров выбрано по silhouette score: **k = 2**.

Профили кластеров:

кластер	N	trend	seasonality	acf1	length	
0	116	0.93	0.32	0.94	236	длиные ряды с сильным трендом
1	34	0.40	0.20	0.45	108	короткие ряды и слабая структура

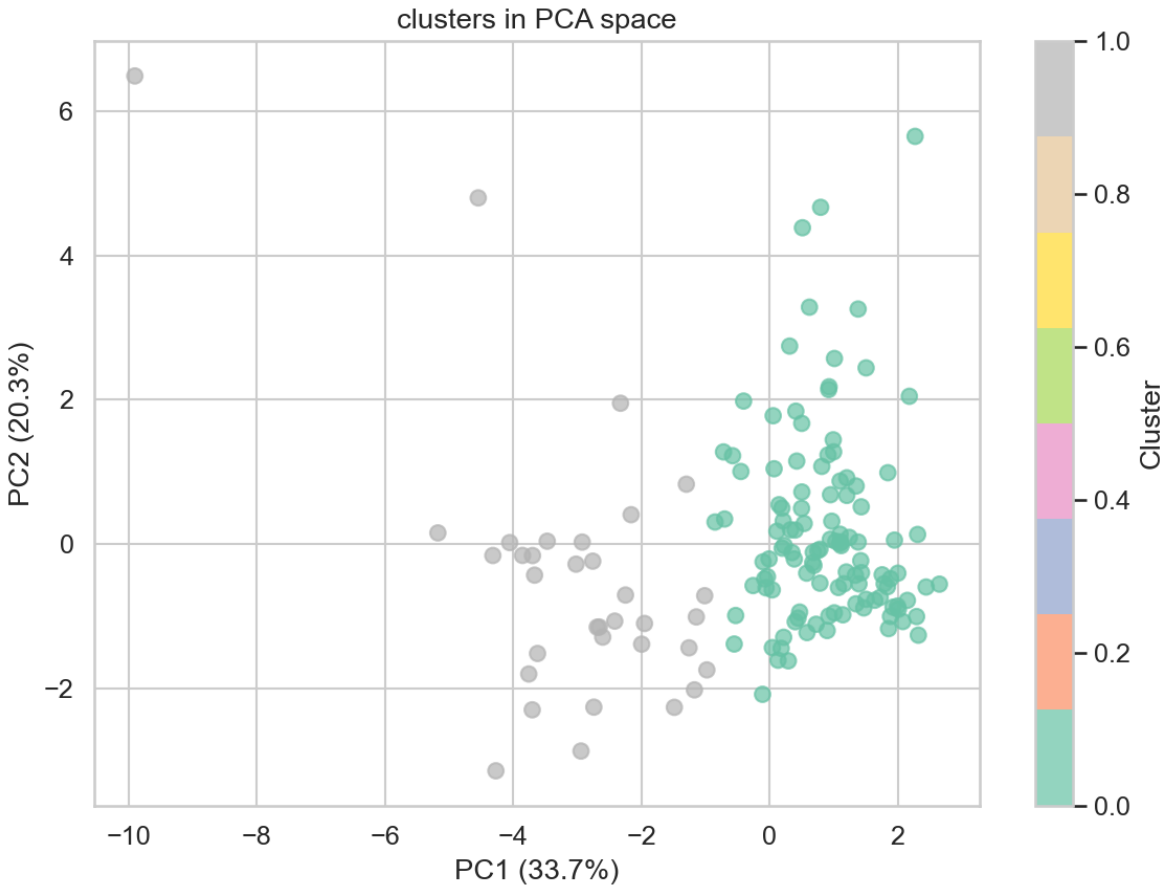

Рис. 1: кластеры в пространстве pca

Бейзлайны

- **Naive** — последнее известное значение
- **SeasonalNaive** — значение из того же сезона прошлого года
- **AutoTheta** — автоматический метод theta
- **AutoETS** — автоматический ETS

бейзлайны были обучены на исходных данных без трансформации

Глобальная модель catboost

Для каждой из четырех трансформаций была обучена одна глобальная модель catboost на всех 150 рядах одновременно. Признаки:

- Лаги: 1–12, 18, 24
- Скользящие статистики: mean и std по окнам 3, 6, 12
- Позиция в сезонном цикле: t mod 12

Прогнозирование — рекурсивная стратегия (предсказание на шаг вперед с подстановкой прогноза в историю)

Метрики

- **sMAPE** — симметричная процентная ошибка, шкала 0–200, не зависит от масштаба ряда
- **MASE** - ошибка, нормированная на сезонный наивный прогноз. MASE < 1 — модель лучше SeasonalNaive, MASE > 1 — хуже

Результаты

Общее сравнение

Модель	Трансформация	sMAPE	MASE
AutoTheta	identity	**14.15**	0.94
AutoETS	identity	14.62	**0.91**
CatBoost	differencing	14.86	1.03
CatBoost	identity	15.72	1.15
CatBoost	boxcox	15.80	1.15
CatBoost	log1p	15.82	1.18
Naive	identity	17.06	1.18
SeasonalNaive	identity	17.55	1.19

катбуст с differencing трансформацией показывает лучший результат среди всех катбустов и приближается к статистическим бейзлайнам autoTheta/AutoETS

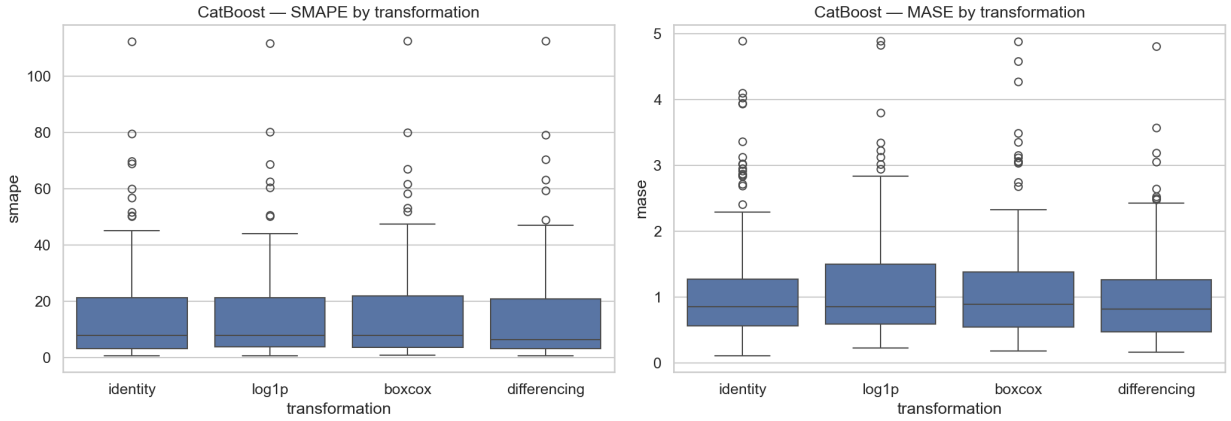

Рис. 2: распределение метрик по трансформациям

Результаты по кластерам

Средний smape:

кластер	boxcox	differencing	identity	log1p
0	12.28	**11.09**	12.20	12.38
1	27.78	27.70	27.72	**27.55**

Средний mase:

кластер	boxcox	differencing	identity	log1p
0	1.18	**1.02**	1.17	1.21
1	**1.04**	1.06	1.08	1.08

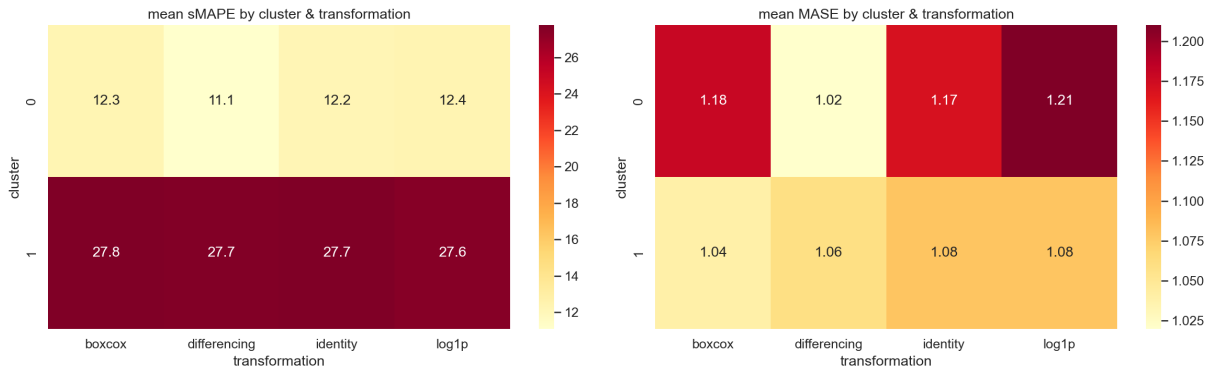

Рис. 3: heatmap

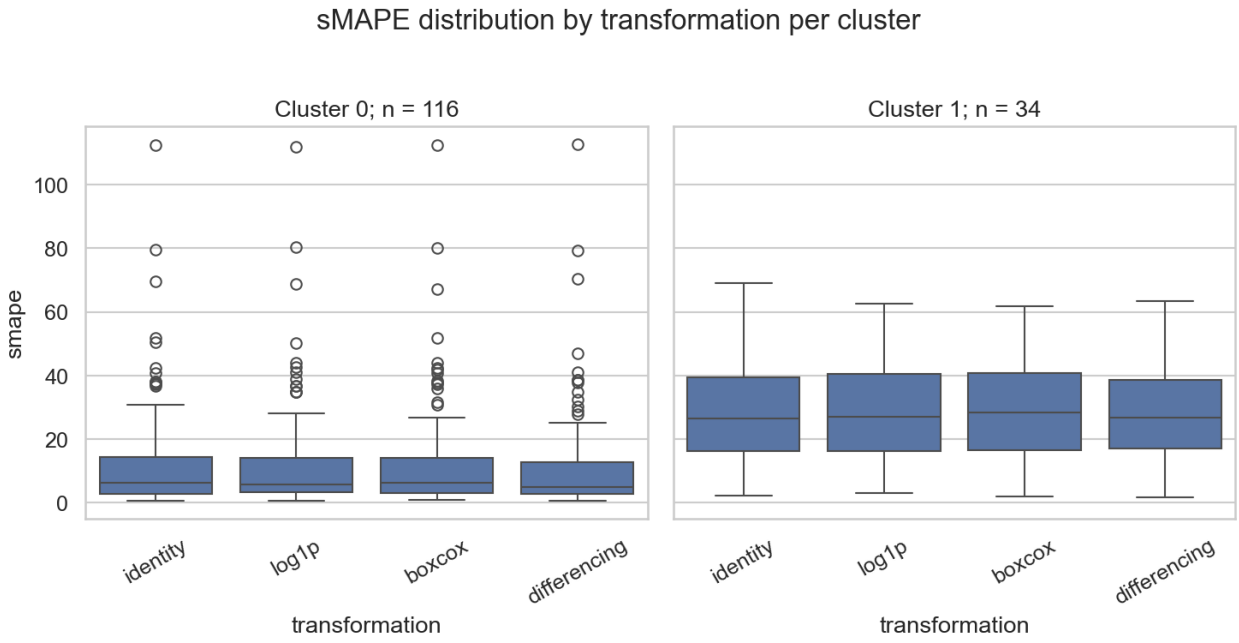

Рис. 4: Распределение smape по трансформациям в каждом кластере

Выводы

- трансформация differencing показала себя лучше всех. Для глобального catboost первые разности дают sMAPE 14.86, что на 0.9 лучше чем без трансформации. differencing убирает нестационарность и модели легче учить паттерны.
- польза от трансформации зависит от типа ряда. Для кластера 0 differencing дает заметный выигрыш, в отличие от кластера 1 (там разница между трансформациями минимальная)
- log1p и box-cox не дают улучшения по сравнению с identity. M4 monthly ряды в основном имеют умеренную дисперсию, так что стабилизация ее через log/box-cox не дает особого профита
- статистические бейзлайны хороши (AuthoTheta и AutoETS) и превосходят глобальный катбуст с лучшей трансформацией